BÀI THỰC HÀNH NLP

Word Embedding tiếng Việt

Word2Vec Skip-gram • Cosine • PCA 2D/3D • t-SNE 2D

Mục tiêu. Xây dựng mô hình biểu diễn từ bằng vector; tìm 10 cặp tương đồng; giảm chiều để quan sát. Mô hình và mọi số liệu trong báo cáo đã được chạy thực tế.

Bài 1. Dữ liệu huấn luyện

Dùng 2.000 bài đầu của bộ **wikimedia/wikipedia**, cấu hình **20231101.vi**, tập **train**, chỉ số hàng 0-1999. Tài liệu bài giảng chỉ dùng làm cơ sở lý thuyết. Không dùng mô hình embedding huấn luyện sẵn.

Chỉ tiêu	Kết quả
Bài nguồn tải về	2.000
Bài còn câu hợp lệ	1.999
Câu sau xử lý	214.886
Token trước lọc min_count	3.805.712
Từ vựng mô hình	23.788
Kích thước embedding	23.788 × 100

Tiền xử lý tiếng Việt

Chuẩn hóa Unicode NFC; loại URL; tách câu gần đúng theo dấu câu và xuống dòng; tách từ bằng **Pyvi**; sau đó chuyển chữ thường. Giữ dấu tiếng Việt và dấu gạch dưới trong từ ghép, ví dụ **máy_tính**.

Loại token chứa số hoặc dấu câu; chỉ giữ câu có ít nhất 3 token; kiểm tra văn bản trùng. Giữ từ chức năng để bảo toàn ngữ cảnh, dùng subsampling trong Word2Vec để giảm ảnh hưởng từ quá phổ biến.

Một bài không còn câu hợp lệ sau xử lý. Mẫu 2.000 bài đầu là mẫu thuận tiện, có thiên lệch chủ đề; không đại diện toàn bộ tiếng Việt. Tách câu bằng quy tắc và tách từ tự động có thể có lỗi.

Cơ sở từ bài giảng

Các từ xuất hiện trong ngữ cảnh tương tự thường có nghĩa gần nhau (tr. 21). Skip-gram dự đoán ngữ cảnh từ từ trung tâm (tr. 38, 50). Negative sampling giảm số trọng số phải cập nhật mỗi bước (tr. 59-61).

Bài 1. Tạo mô hình Word2Vec

Với cặp dương gồm từ trung tâm **c** và từ ngữ cảnh **o**, mô hình tăng điểm của cặp thật và giảm điểm của các cặp với từ âm. Hàm mất mát:

$$L(c,o) = -\log \sigma(u_o \cdot v_c) - \Sigma_{i=1..10} \log \sigma(-u_{n_i} \cdot v_c)$$

σ là sigmoid; dấu · là tích vô hướng; v là vector đầu vào; u là vector đầu ra; n_i là từ âm. Từ âm được lấy mẫu theo tần suất mũ 0,75. Hai ma trận trọng số có kích thước |V| × 100. Lấy ma trận đầu vào qua **model.wv** làm embedding.

Tham số	Giá trị	Ý nghĩa
sg / hs	1 / 0	Skip-gram; dùng negative sampling
vector_size / window	100 / 5	100 chiều; bán kính cửa sổ tối đa 5
min_count / negative	5 / 10	Bỏ từ dưới 5 lần; 10 mẫu âm
epochs / sample	15 / 0.001	15 lượt; giảm lấy mẫu từ phổ biến
workers / seed	1 / 42	Ổn định thứ tự học và khởi tạo

Mã huấn luyện cốt lõi

```
from gensim.models import Word2Vec
from gensim.models.word2vec import LineSentence

sentences = LineSentence("data/corpus_tokenized.txt")
model = Word2Vec(
    vector_size=100, window=5, min_count=5, sg=1,
    negative=10, hs=0, sample=1e-3,
    epochs=15, workers=1, seed=42,
    hashfxn=stable_hash
)
model.build_vocab(sentences)
model.train(sentences, total_examples=model.corpus_count,
            epochs=model.epochs)
vector = model.wv["máy_tính"]
model.save("models/word2vec_vi.model")
```

Đoạn trên rút gọn từ chương trình đầy đủ. Hàm **stable_hash** dùng CRC32, được định nghĩa trong mã nguồn và notebook. Pyvi dùng bộ tách từ có sẵn; trọng số Word2Vec được học mới từ corpus.

Kết quả huấn luyện

Ma trận embedding có **23.788 hàng × 100 cột**. Thời gian của lần chạy: **281.4 giây**, không gồm tải dữ liệu và tách từ. Đã lưu mô hình đầy đủ và bộ vector riêng.

Tệp .model hỗ trợ huấn luyện tiếp; tệp .kv phù hợp nạp vector để truy vấn. Notebook có thao tác lưu/nạp và kiểm tra vector giữ nguyên. Tham số và phiên bản thư viện nằm trong training_metadata.json.

Bài 2. Tìm 10 cặp tương đồng

cosine(v,w) = (v · w) / (||v||$_2$ ||w||$_2$)

Tính cosine trên vector **100 chiều gốc**. Với 10 từ truy vấn chọn trước, lấy láng giềng gần nhất trong toàn bộ từ vựng; loại chính từ truy vấn và cặp đảo chiều bị trùng. Đây là 10 cặp theo truy vấn, không phải top 10 cặp toàn cục.

STT	Từ truy vấn	Láng giềng	Cosine	Hạng
1	học_sinh	sinh_viên	0.7978	1
2	giáo_viên	dạy	0.6725	1
3	bác_sĩ	y_sĩ	0.7116	1
4	bệnh_viện	đa_khoa	0.8078	1
5	máy_tính	phần_cứng	0.7938	1
6	điện_thoại	email	0.7226	1
7	ô_tô	xe_hơi	0.7752	1
8	bóng_đá	đội_tuyển	0.8137	1
9	âm_nhạc	vũ_đạo	0.7241	1
10	toán_học	giải_tích	0.7319	1

Dấu gạch dưới nối các thành tố trong một token. Tần suất từng từ và giá trị cosine đầy đủ được lưu trong results/10_cap_tuong_dong.csv.

Đọc kết quả đúng

Cosine thuộc [-1, 1]; càng gần 1 thì hai vector càng cùng hướng. Cosine không phải xác suất hay độ chính xác. Tương đồng phân bố có thể biểu thị cùng loại hoặc liên quan chủ đề, không nhất thiết đồng nghĩa (trang 7 của tài liệu).

Không dùng vị trí điểm trên biểu đồ để chọn hoặc sửa các cặp. Các cặp được xác định trước bước giảm chiều. Chưa có bộ chuẩn do người gán điểm nên không khẳng định mô hình đạt chất lượng ngữ nghĩa tổng quát.

Ví dụ: ô_tô / xe_hơi là đồng nghĩa; học_sinh / sinh_viên cùng nhóm người học. giáo_viên / dạy và bóng_đá / đội_tuyển chủ yếu liên quan ngữ cảnh. Đây là giới hạn thực tế của mô hình phân bố.

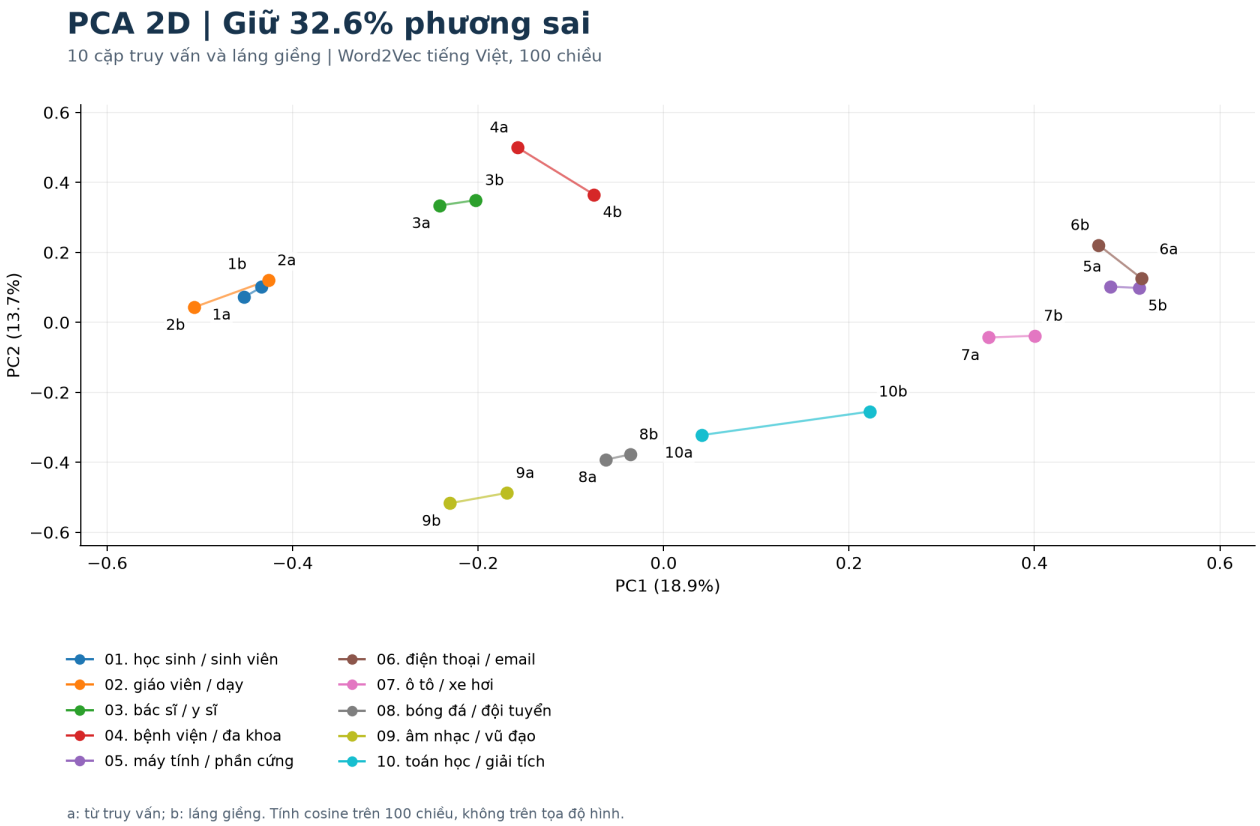
Mã tìm cặp

```
for word in QUERY_WORDS:
    nearest, score = model.wv.most_similar(word, topn=1)[0]
    print(word, nearest, round(score, 4))
```

Hàm find_pairs trong mã đầy đủ bổ sung kiểm tra từ ngoài từ vựng và loại cặp trùng. Hạng trong bảng ghi đúng vị trí láng giềng được chọn.

Bài 2. Giảm từ 100 chiều xuống 2D

Tập chiếu gồm **20 từ riêng biệt** trong 10 cặp. Chuẩn hóa L2 mỗi vector trước PCA. PCA chỉ fit trên tập từ này; không dùng toàn bộ 23.788 từ.



a: từ truy vấn; b: láng giềng. Tính cosine trên 100 chiều, không trên tọa độ hình.

Phương pháp PCA

Gọi X là ma trận vector đã chuẩn hóa, μ là trung bình theo từng chiều. PCA tìm các hướng có phương sai lớn nhất. Với U_2 chứa hai hướng đầu tiên: $\mathbf{Z_2 = (X - \mu)U_2}$.

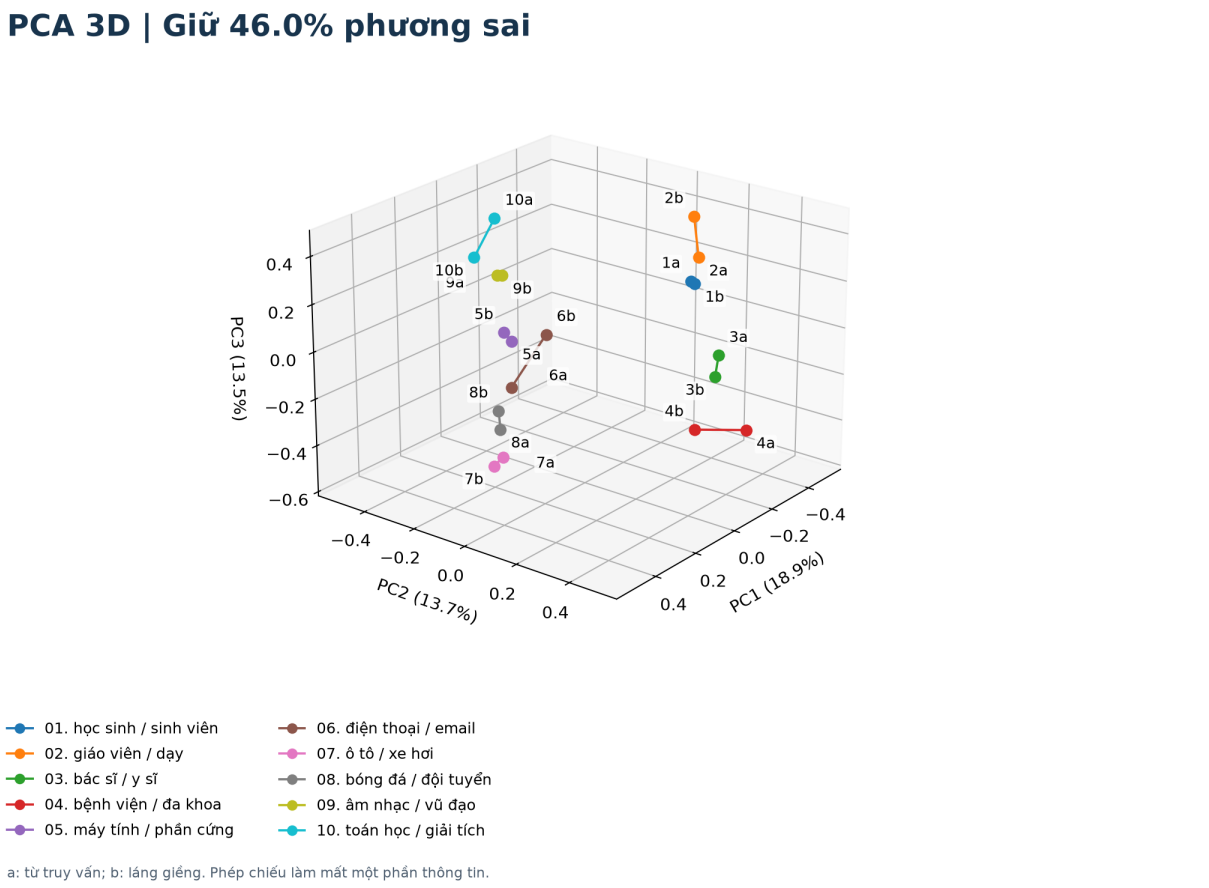
PC1 giữ **18.90%** và PC2 giữ **13.66%** phương sai. Tổng hai chiều giữ **32.56%** phương sai của tập từ hiển thị. Phần còn lại bị mất trong hình chiếu.

```
vectors = np.vstack([model.wv[w] for w in words])
X = vectors / np.linalg.norm(vectors, axis=1, keepdims=True)
pca = PCA(n_components=3, svd_solver="full")
Z3 = pca.fit_transform(X)
Z2 = Z3[:, :2]
```

Nhãn a là từ truy vấn, b là láng giềng. Màu và đoạn nối chỉ đánh dấu 10 cặp đã biết, không phải kết quả phân cụm. Quan hệ trên hình chỉ có tính gợi ý (trang 69).

Bài 2. Giảm từ 100 chiều xuống 3D

Dùng cùng phép PCA, giữ thêm thành phần thứ ba. PC3 giữ **13.45%**; ba chiều giữ tổng cộng **46.01%** phương sai của tập từ hiển thị.



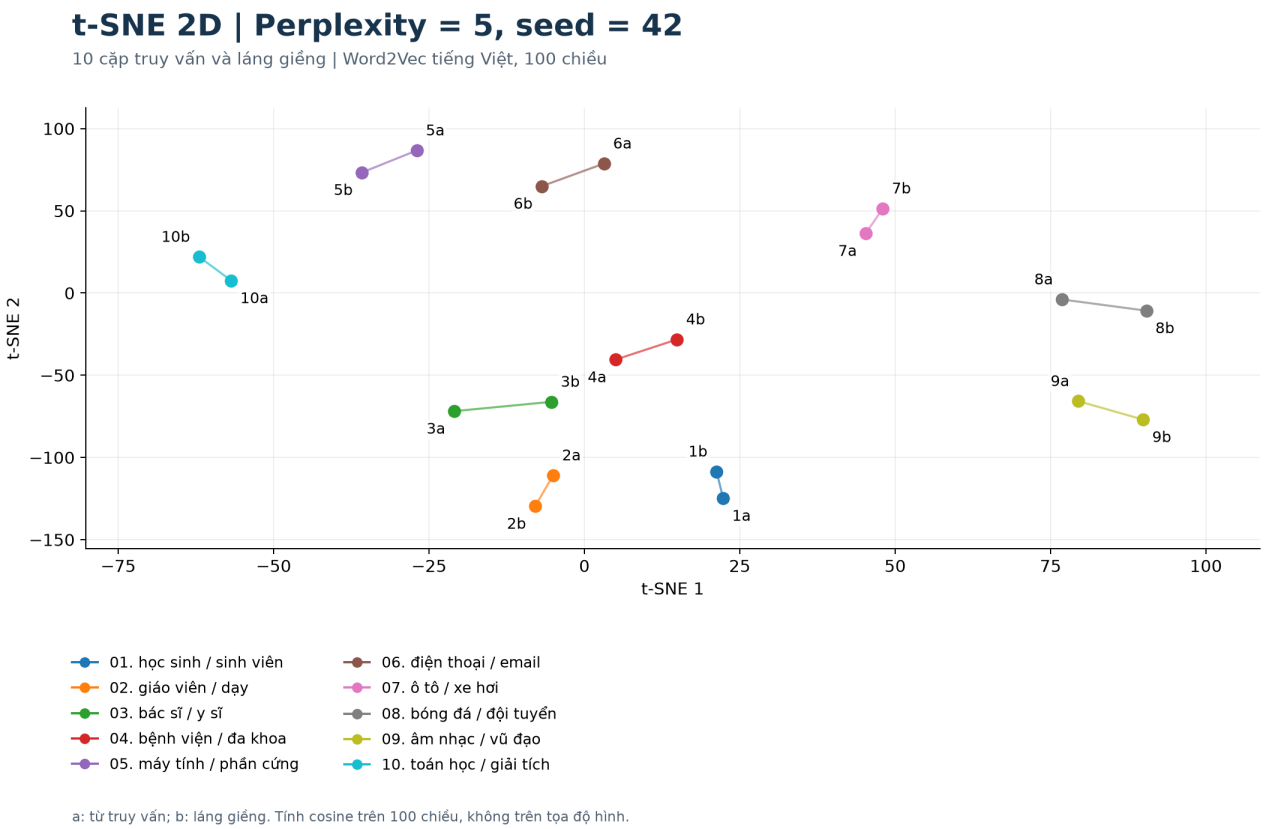
Đầu ra 2D và 3D

Biểu diễn	Kích thước	Tệp lưu
Vector gốc	20 × 100	results/vectors_and_projection.npz
PCA 2D	20 × 2	Hai cột PCA_PC1, PCA_PC2 trong CSV
PCA 3D	20 × 3	Ba cột PCA_PC1, PCA_PC2, PCA_PC3
t-SNE 2D	20 × 2	Hai cột TSNE_1, TSNE_2 trong CSV

Tọa độ đầy đủ nằm trong **results/toa_do_2d_3d.csv**. Tệp NPZ còn chứa vector gốc, trung bình và ma trận thành phần PCA để kiểm tra phép chiếu. Hai cột đầu của PCA 3D chính là PCA 2D.

Dù giữ thêm một chiều, PCA 3D vẫn làm mất thông tin. Hướng và dấu trục không mang nghĩa từ vựng cố định; không dùng khoảng cách nhìn thấy để thay thế cosine 100D.

Bổ sung. t-SNE 2D và nhận xét



a: từ truy vấn; b: láng giềng. Tính cosine trên 100 chiều, không trên tọa độ hình.

t-SNE dùng perplexity = 5, seed = 42, 1.500 vòng lặp, khởi tạo PCA; chạy trên cùng các vector đã chuẩn hóa L2. Với vector đơn vị, khoảng cách Euclidean bình phương bằng 2 × (1 - cosine).

t-SNE ưu tiên bảo toàn láng giềng cục bộ. Với tập điểm nhỏ, hình phụ thuộc mạnh vào tham số và các từ được chọn. Khoảng cách giữa cụm không phải thước đo ngữ nghĩa đáng tin cậy.

Kết luận và giới hạn

Đã tạo mô hình Word2Vec tiếng Việt, tìm đủ 10 cặp và xuất tọa độ 2D/3D. Kiểm tra lại cosine bằng tích vô hướng; kiểm tra số chiều, giá trị hữu hạn và vector sau khi lưu/nạp. Chất lượng vẫn bị giới hạn bởi corpus nhỏ, lỗi tách từ và embedding tĩnh gộp các nghĩa của mỗi token.

Nguồn tham khảo

1. Vương Thị Hải Yến. *3. Semantics-WordEmbedding.pdf*, tài liệu người dùng cung cấp: tr. 7, 21, 26, 38, 49-50, 59-61, 69, 74.
2. Wikimedia Wikipedia, 20231101.vi. Cộng đồng Wikipedia; thẻ dữ liệu: CC BY-SA 3.0 / GFDL. URL từng bài và mô tả thay đổi lưu trong gói dữ liệu, README.
3. Gensim Word2Vec; Pyvi.
4. scikit-learn: PCA, t-SNE.